

Technical Analysis Document

Industrial Anomaly Detection per Componenti di Macchinari — Progetto Computer Vision, Epicode Institute of Technology

Studente	Corinne D'Aquino
Dataset	MVTec AD (metal_nut, screw, grid) + Ball Screw Dataset (KIT)
Repository	github.com/CorinneD-0/cv-maintenance-anomaly
Sessione	Giugno–Luglio 2026

1. Problem Statement

Nel mio lavoro quotidiano in Sidel/Tecnodinamica gestisco i piani di manutenzione per macchine da packaging, lavorando con un sistema chiamato TACS. Ho analizzato 8.395 attività di manutenzione e ho notato che una parte significativa riguarda inspection visive periodiche su componenti meccanici come cuscinetti, viti, ingranaggi e cinghie di trasmissione.

Il problema è che queste ispezioni vengono eseguite da tecnici del cliente — non sempre esperti come quelli Sidel — che devono giudicare a occhio se un componente è ancora in buono stato oppure va sostituito. Questa valutazione è inevitabilmente soggettiva e dipende dall'esperienza del singolo tecnico.

Ho quindi pensato di costruire un sistema di Computer Vision che assistesse il tecnico durante il check visivo: fotografa il componente, e il sistema risponde con una valutazione automatica. L'approccio scelto è unsupervised perché in produzione i componenti difettosi sono rari per definizione — non ci sarebbero abbastanza esempi negativi per addestrare un modello supervisionato.

2. Metodologia

2.1 Dataset

Ho usato due dataset pubblici. Il principale è MVTEC Anomaly Detection (Bergmann et al., 2019), lo standard di riferimento per l'anomaly detection industriale. Ho scelto tre categorie tra le più vicine ai componenti Sidel che gestisco: metal_nut (bulloni), screw (viti) e grid (reti metalliche simili a conveyor). In aggiunta ho incluso il Ball Screw Dataset del KIT, specifico per componenti meccanici soggetti a usura progressiva — molto rilevante per il contesto manutenzione.

2.2 Preprocessing

Tutte le immagini vengono portate a 224x224 pixel e normalizzate con le statistiche ImageNet (mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]). La scelta di 224x224 è dettata dall'architettura EfficientNet-B0 usata come backbone. Per il training set ho aggiunto augmentation leggera (flip orizzontale, rotazioni, variazioni di luminosità) per rendere il modello più robusto alle condizioni di illuminazione variabili tipiche di un ambiente industriale.

2.3 Approccio classico: HOG + OneClassSVM

Il primo modello usa feature handcrafted. HOG (Histogram of Oriented Gradients, Dalal & Triggs 2005) descrive la struttura locale dell'immagine attraverso istogrammi delle orientazioni dei gradienti su celle 8x8 pixel — cattura bordi, texture e forma dei componenti. Il vettore risultante (6.084 dimensioni) viene passato a un OneClassSVM con kernel RBF, addestrato solo su immagini normali. Il modello costruisce un confine attorno alla distribuzione normale e classifica come anomalia tutto ciò che cade fuori.

2.4 Approccio deep learning: PatchCore

PatchCore (Roth et al., 2022) è lo stato dell'arte per l'anomaly detection industriale unsupervised. Usa EfficientNet-B0 pre-addestrato su ImageNet come backbone congelato per estrarre feature da patch dell'immagine. Le feature vengono estratte da due layer intermedi (layer 2 e layer 4) per catturare informazione a scale diverse. Dalle immagini di training viene costruita una memory bank tramite coreset subsampling greedy — un sottoinsieme rappresentativo delle feature normali. A inference, la distanza nearest-neighbor dalla memory bank costituisce l'anomaly score. La memory bank finale contiene tra 68k e 100k vettori a seconda della categoria.

Ho scelto EfficientNet-B0 come backbone perché con soli 5.3M di parametri è il bilanciamento ideale tra capacità rappresentativa e rischio di overfitting su dataset di training piccoli (220–320 immagini per categoria). Il backbone non viene fine-tuned: le feature pre-addestrate su ImageNet sono sufficientemente generali da trasferirsi bene al dominio industriale.

2.5 Layer di spiegazione: Gemma4:e4b

Come componente aggiuntivo (bonus multimodale) ho integrato Gemma4:e4b, un modello linguistico multimodale open-source di Google, tramite Ollama in esecuzione locale. Quando PatchCore rileva un'anomalia, l'immagine viene inviata a Gemma4 insieme all'anomaly score per ottenere una spiegazione testuale del tipo di difetto. La scelta del modello locale è intenzionale: in contesto IIoT le immagini dei componenti industriali contengono informazioni sensibili sui processi produttivi e non devono uscire dalla rete aziendale.

2.6 Post-processing e localizzazione

PatchCore genera una heatmap di anomalia che visualizza dove nell'immagine è concentrata l'anomalia. Ogni patch dell'immagine ottiene un anomaly score, interpolato e sovrapposto all'immagine originale in una mappa colorata (verde = normale, rosso = anomalia). Questa visualizzazione è pensata specificatamente per il tecnico di manutenzione, che ha bisogno di sapere non solo se c'è un problema ma anche dove guardare.

3. Risultati Sperimentali

La tabella seguente riassume le performance dei due modelli sulle tre categorie del dataset MVTec AD. Per PatchCore vengono riportati i risultati con la memory bank completa (coreset greedy senza pre-subsampling).

Dataset	Modello	AUROC	Avg Prec	F1	Precision	Recall
metal_nut	HOG+SVM	0.825	0.954	0.829	0.958	0.731
metal_nut	PatchCore	0.959	0.991	0.906	1.000	0.828
screw	HOG+SVM	0.769	0.884	0.876	0.862	0.891
screw	PatchCore	0.883	0.935	0.808	0.976	0.689
grid	HOG+SVM	0.614	0.795	0.652	0.857	0.526
grid	PatchCore	0.757	0.909	0.697	0.969	0.544

Il risultato piu' interessante e' che i due modelli si comportano diversamente a seconda della categoria. Su metal_nut, PatchCore domina nettamente (AUROC 0.959 vs 0.825) — i bulloni hanno forme tridimensionali e geometrie complesse che le feature deep di EfficientNet catturano meglio dei gradienti HOG. Su screw invece HOG+SVM ottiene un Recall molto piu' alto (0.891 vs 0.689): le viti hanno un pattern di filettatura regolare che HOG descrive efficacemente con i suoi istogrammi di orientazione.

Su grid entrambi i modelli faticano. La griglia metallica ha una texture ripetitiva fine dove i difetti sono piccole rotture del pattern — difficili sia per HOG (troppo grossolano) che per PatchCore con la memory bank attuale. PatchCore mantiene comunque una Precision molto alta (0.969) — quando dice che c'e' un'anomalia ha quasi sempre ragione.

4. Failure Analysis

Dataset	Modello	False Positives	False Negatives
metal_nut	HOG+SVM	3	25
metal_nut	PatchCore	0	16
screw	HOG+SVM	17	13
screw	PatchCore	2	37
grid	HOG+SVM	5	27
grid	PatchCore	1	26

Il dato piu' rilevante per un contesto industriale e' il numero di False Negatives (FN) — i difetti reali che il sistema non rileva. In manutenzione predittiva un FN e' molto piu' pericoloso di un FP: un pezzo difettoso che supera il controllo puo' causare guasti improvvisi e fermi produzione non pianificati.

PatchCore su metal_nut ha FP=0 (non fa mai falsi allarmi) con FN=16. HOG+SVM fa piu' falsi allarmi (FP=3) ma si perde meno difetti (FN=25 vs 16). Su screw la situazione si inverte: HOG+SVM e' piu' bilanciato (FP=17, FN=13), mentre PatchCore tende a essere conservativo (FP=2 ma FN=37).

Il comportamento conservativo di PatchCore (alta Precision, basso Recall) e' probabilmente legato alla natura del coreset subsampling: anche con una memory bank grande, il campionamento greedy potrebbe non coprire uniformemente tutti i tipi di componente normale, rendendo il modello selettivo nelle predizioni. Un possibile miglioramento e' aumentare il coreset_ratio o usare stratificazione per tipo di difetto.

5. Considerazioni Etiche e Limiti

5.1 Privacy e data sovereignty

Le immagini dei componenti industriali possono contenere informazioni sensibili sui processi produttivi di clienti come Coca-Cola o Peroni. Per questo motivo ho scelto deliberatamente un modello di spiegazione locale (Gemma4 via Ollama) invece di API cloud. Tutta l'elaborazione avviene on-premise senza trasmissione di dati all'esterno.

5.2 Bias del dataset

MVTec AD e' stato creato in Europa con componenti industriali europei. I modelli addestrati potrebbero avere performance diverse su componenti di produzione asiatica o con finiture superficiali diverse. Prima di un deployment reale in Sidel sarebbe necessario validare il sistema su immagini reali dei componenti effettivamente usati nelle macchine.

5.3 Il sistema e' un supporto, non un sostituto

Con Recall tra il 54% e il 89% a seconda del modello e della categoria, il sistema non puo' sostituire l'ispezione umana. E' pensato come un primo filtro che aiuta il tecnico a focalizzare l'attenzione, non come un decisore autonomo. La heatmap di localizzazione serve proprio a questo: mostrare dove guardare, lasciando al tecnico la valutazione finale.

5.4 Trasparenza degli errori

Ho incluso una failure analysis dettagliata perche' ritengo che documentare dove il sistema sbaglia sia parte integrante di un approccio responsabile all'AI industriale. Un sistema che non dichiara i propri limiti e' potenzialmente piu' pericoloso di uno che li rende espliciti.

5.5 Limiti tecnici e sviluppi futuri

Il Ball Screw Dataset e' attualmente integrato nella struttura del codice ma non nei risultati finali per mancanza di etichette standardizzate. Uno sviluppo futuro sarebbe raccogliere immagini reali dei componenti Sidel e usare il sistema pre-addestrato come punto di partenza, adattandolo con transfer learning sul dominio specifico. Un'altra estensione interessante sarebbe integrare il sistema direttamente in TACS — il gestionale di manutenzione gia' in uso — per automatizzare la registrazione dei controlli visivi con evidenza fotografica.